



## FCN(5)——DenseCRF推导



冯超

《强化学习精要》《深度学习轻松学》作者, 咨询请值乎

27 人赞了该文章

本文收录在[无痛的机器学习第一季](#)。

经过前两篇文章，我们了解了CRF的基本概念，了解了许许多多的CRF模型，也了解了Mean field variational inference的基本概念，那么这一回我们开始真刀真枪地进行公式推导。其实公式推导的部分在论文的补充材料里有，但是不够详尽，这里我们尽可能地补充一下，让推导过程更加完整。

### DenseCRF

前面我们已经看过了DenseCRF的能量函数，如下所示

$$E(x) = \sum_i \psi_u(x_i) + \sum_{i < j} \psi_p(x_i, x_j)$$

其他内容在这就不说了，我们抓紧时间推导。

### Variational Inference推导

我们首先给出denseCRF的Gibbs分布：

$$P(X) = \frac{1}{Z} \tilde{P}(X) = \frac{1}{Z} \exp(\sum_i \psi_u(x_i) + \sum_{i < j} \psi_p(x_i, x_j))$$

下面给出KL散度部分的推导，其实就是补充材料中的推导，搬运工来了.....

$$\begin{aligned} D(Q||P) &= \sum_x Q(x) \log\left(\frac{Q(x)}{P(x)}\right) = - \sum_x Q(x) \log P(x) + \sum_x Q(x) \log Q(x) \\ &= -E_{X \in Q}[\log P(X)] + E_{X \in Q}[\log Q(X)] \\ &= -E_{X \in Q}[\log \tilde{P}(X)] + E_{X \in Q}[\log Z] + \sum_i E_{X_i \in Q}[\log Q_i(X_i)] \\ &= -E_{X \in Q}[\log \tilde{P}(X)] + \log Z + \sum_i E_{X_i \in Q_i}[\log Q_i(X_i)] \end{aligned}$$

由于我们要求的是Q，而logZ项中没有Q，所以这一项可以省略。

同时Q还需要满足：

$$\sum_{x_i} Q_i(x_i) = 1$$

所以利用拉格朗日乘子法，可以得到

$$L(Q_i) = -E_{X_i \in Q}[\log \tilde{P}(X)] + \sum_i E_{x_i \in Q_i}[\log Q_i(x_i)] + \lambda(\sum_{x_i} Q_i(x_i) - 1)$$

这个公式的后面两项相对比较简单，但是前面一项比较复杂，我们单独做一下处理：

$$\begin{aligned} -E_{X_i \in Q}[\log \tilde{P}(X)] &= - \int \prod_i Q_i(x_i) [\log \tilde{P}(X)] dX \\ &= - \int Q_i(x_i) \prod_{\bar{i}} Q(\bar{x}_i) [\log \tilde{P}(X)] dx_i d\bar{X} \\ &= - \int Q_i(x_i) E_{\bar{X} \in Q}[\log \tilde{P}(X)] dx_i \end{aligned}$$

经过上面的公式整理，我们可以求出偏导，

赞同 27

20 条评论

分享

收藏

...



$$\frac{\partial L(Q_i)}{\partial Q_i(x_i)} = -E_{\tilde{X} \in Q_i}[\log \tilde{P}(X|x_i)] - \log Q_i(x_i) - 1 + \lambda$$

令偏导为0，就可以求出极值：

$$Q_i(x_i) = \exp(\lambda - 1) \exp(-E_{\tilde{X} \in Q_i}[\log \tilde{P}(X|x_i)])$$

由于每一个Q的  $\exp(\lambda - 1)$  都相同，我们将其当作一个常数项，之后在renormalize的时候将其抵消掉，于是Q函数就等于：

$$Q(x_i) = \frac{1}{Z_1} \exp(-E_{\tilde{X} \in Q_i}[\log \tilde{P}(X|x_i)])$$

我们将文章开头关于  $\tilde{P}$  的定义带入，就得到了

$$Q(x_i) = \frac{1}{Z_1} \exp(-E_{\tilde{X} \in Q}[(\sum_i \psi_u(x_i) + \sum_{j \neq i} \psi_p(x_i, x_j))|x_i])$$

这里面xi的由于是已知的，所以我们可以得到补充材料里的结果（但是变量名不太一样）：

$$Q_i(x_i = l) = \frac{1}{Z_i} \exp[-\psi_u(l) - \sum_{j \neq i} E_{\tilde{X} \in Q_j} \psi_p(l, X_j)]$$

继续扩展，就可以得到

$$\begin{aligned} &= \frac{1}{Z_i} \exp[-\psi_u(l) - \sum_{m=1}^K w^{(m)} \sum_{j \neq i} E_{X \in Q_j} [\mu(l, X_j) k^{(m)}(f_i, f_j)]] \\ &= \frac{1}{Z_i} \exp[-\psi_u(l) - \sum_{m=1}^K w^{(m)} \sum_{j \neq i} \sum_{l' \in L} Q_j(l') \mu(l, l') k^{(m)}(f_i, f_j)] \\ &= \frac{1}{Z_i} \exp[-\psi_u(l) - \sum_{l' \in L} \mu(l, l') \sum_{m=1}^K w^{(m)} \sum_{j \neq i} Q_j(l') k^{(m)}(f_i, f_j)] \end{aligned}$$

这样，一个类似message passing的公式推导就完成了。其中最内层的求和可以用截断的高斯滤波完成。搬运最后的一点公式，可以得：

$$Q_i^{(\tilde{m})}(l) = \sum_{j \neq i} Q_j(l') k^{(m)}(f_i, f_j) = \sum_j Q_j(l) k^{(m)}(f_i, f_j) - Q_i(l)$$

上面公式的第一项可以转化成卷积操作。

完成了这些推导，下面我们暂时不给出denseCRF的单独结果，我们下面看看FCN和DenseCRF结合的效果，FCN已经等的花都谢了.....

## 广告时间

更多精彩尽在《深度学习轻松学：核心算法与视觉实践》！

编辑于 2017-11-22

[机器学习](#) [深度学习 \(Deep Learning\)](#) [概率图模型](#)

## 文章被以下专栏收录



无痛的机器学习

专栏主营业务：让更多人能看懂的机器学习科普+进阶文章。欢迎各位大神投稿或协...

进入专栏

▲ 赞同 27 ▼

● 20 条评论

➦ 分享

★ 收藏

...

FCN(3)——DenseCRF

本文收录在无痛的机器学习第一季。上一回我们简单介绍了无向图模型和CRF的基本概念，下面我们来看看CRF在图像分割问题上的具体应用。我们简单回忆一下CRF中的两个关键变量，这时我们需要...

冯超

FCN(2)——CRF通俗非严谨的入门

本文收录在无痛的机器学习第一季。前面我们简单介绍了FCN——这个将High-Level任务转到Low-Level任务的模型。这里的High和Low并不是我们通常意义中的High和Low，两种任务并没有高低之...

冯超



《机器学习》笔记-概率(14)

刘才权

发表于机器

20 条评论

切换为时间排序

写下你的评论...



GD hao

1 年前

公式没有加\$ \$?

赞



冯超 (作者) 回复 GD hao

1 年前

?

赞

查看对话



Zephyr-D

1 年前

建议最关键的Message Passing和Gaussian Filter部分可以展开一下..

赞



冯超 (作者) 回复 Zephyr-D

1 年前

好，我后面扩展一下

赞

查看对话



chiehchiu

1 年前

请问下公式中的P (x) 和Q (x) 分别带到图像分割中分别代表什么呢?

赞



冯超 (作者) 回复 chiehchiu

1 年前

p(x)和Q(x)实际上描述的是同一个东西，p(x)描述了x的联合概率，这里的x指的是每一个像素所属类别。

Q(x)只是满足mean field的联合概率，含义和上面那个一样，只是相对好求些

赞

查看对话



高首

1 年前

想请问一下是在哪搬运的?

赞



冯超 (作者) 回复 高首

1 年前

论文的补充材料有一些推导，但里面的推导不够细致

赞

查看对话



董明辉

1 年前

你好 文中的有些公式好像显示不出来了 可否更新一下，或者是我网络的问题？非常感谢

赞

赞同 27

20 条评论

分享

收藏

...



cjfuture

1 年前

请问，单独处理的那一部分第一步怎么得到的，没看懂，谢谢

👍 赞



Hatiim

1 年前

您好，我在读DenseCRF的源码时发现，对于兼容度转换使用最简单的方法Potts模型[ $x_i \neq x_j$ ]，兼容度转换 $u(l,l')$ 在代码中具体好像什么都没做，而直接是把两个核加起来乘以权重。而我理解的不是应该将不同类别的 $Q_i(l')$ (除当前类别 $l$ 外)求和吗？请问博主清楚吗？

👍 赞



parallel shadow

1 年前

冯老爷你好，“经过上面的公式整理，我们可以求出偏导，可得”后面的那个公式，我推出来的结果是把 $-\log Q_i(x_i) - 1$ 改成 $\log Q_i(x_i) + 1$ 。请教一下哪里出问题了~

👍 赞



冯超 (作者) 回复 parallel shadow

1 年前

你的公式推导过程是怎样的？

👍 赞    💬 查看对话



parallel shadow 回复 冯超 (作者)

1 年前

就是 $L(Q_i)$ 的中间项： $\sum_j E_{x_i \in Q_i} [\log Q_i(x_i)]$ 。对里面的 $E_{x_i \in Q_i} [\log Q_i(x_i)]$ 求导，再进 $Q_i(x_i) \log Q_i(x_i)$ 求导，不就是 $\log Q_i(x_i) + 1$ 吗？

👍 赞    💬 查看对话



Don't 回复 冯超 (作者)

10 个月前

我求导后那部分也是和shadow一样，上面的公式推导写错了吧；另外单独处理的部分实在没看懂怎么就变成积分里还连乘了，整个单独处理部分都没太懂，楼主有什么参考文献吗？

👍 赞    💬 查看对话



艺小洲 回复 Don't

4 个月前

补充材料里面的公式(3)写错了，应该是

\$\$

$$P(X) = \frac{1}{Z} \exp(-E(X))$$

\$\$

然后这篇文章求导部分符号推错了

👍 2    💬 查看对话



艺小洲 回复 Don't

4 个月前

连乘是因为变量假设独立  $Q(X) = \prod_i Q_i(X_i)$

👍 赞    💬 查看对话



Jane

2 个月前

建议大神把Gaussian Filter部分展开一下~

👍 赞



liang

1 个月前

"公式推导的部分在论文的补充材料里有"，能不能给个论文补充材料的链接？我没找到，谢谢！

👍 赞



陈亮 回复 冯超 (作者)

1 个月前

冯老师扩展了吗？给下链接

👍 赞    💬 查看对话